

Presentación Técnica Final — NextAgent

Plataforma de Creación y Despliegue de Agentes de IA Verificables

Equipo: Oscar David Rojas Bedoya · Yesid Alejandro Peláez Posada
Proyecto: Beca IA Ser ANDI — Reto EAFIT x Verana
Fecha: Mayo 2026

1. Arquitectura Técnica

La plataforma **NextAgent** utiliza una arquitectura de microservicios orquestada en **Kubernetes** (namespace **team-g**). Se divide en tres capas principales:

- Frontend (React + Vite):** Interfaz de usuario intuitiva que permite gestionar el ciclo de vida de los agentes.
- Backend (Node.js + Express):** Actúa como el orquestador, gestionando la lógica de negocio, la persistencia y la comunicación con el cluster de Kubernetes mediante Helm.
- Capa de Agentes:** Cada bot publicado es un despliegue independiente que contiene:
 - Chatbot (Hologram AI Agent):** El motor de conversación.
 - VS Agent (Verana):** La capa de identidad y comunicación DIDComm.

Diagrama de Arquitectura

Arquitectura del Proyecto *(Nota: Reemplazar con la imagen de soporte proporcionada)*

2. Flujo de Datos

El flujo de información en NextAgent está diseñado para ser asíncrono y seguro:

- Configuración:** El usuario define el "Persona" del agente (nombre, prompt, herramientas MCP).
- Generación de Assets:** El backend genera dinámicamente archivos **agent-pack.yaml** y valores de Helm específicos para ese bot.
- Despliegue:** Se ejecuta un comando **helm upgrade** que levanta los pods en el cluster.
- Verificación de Identidad:** Una vez el pod está activo, el backend detecta el DID del agente y solicita automáticamente una **Credencial Verificable** a la autoridad de confianza (EAFIT).
- Publicación:** El bot queda disponible en la red Verana y se genera un QR de invitación OOB para que los usuarios lo agreguen en la app Hologram.

3. Bases de Datos Utilizadas

El sistema implementa una estrategia de persistencia híbrida:

- SQLite (Plataforma):** Utilizada por el servidor central de NextAgent para gestionar usuarios, perfiles de bots y estados de publicación de forma ágil y ligera.

- **PostgreSQL (Agentes):** Instancia compartida donde cada bot posee su propio **Schema dedicado**. Aquí se almacenan los logs de auditoría y estados persistentes de cada agente.
 - **Redis (Memoria y Vectores):** Utilizada por los bots para la memoria de corto plazo (ventana de conversación) y como motor de búsqueda semántica para los documentos RAG (Retrieval-Augmented Generation).
-

4. APIs, Modelos y Servicios Implementados

- **Modelos de Lenguaje (LLM):** Uso de **GPT-4o-mini** (vía OpenAI) y **Llama 3.2** (vía Ollama local) mediante una interfaz compatible con OpenAI.
 - **Servidores MCP (Model Context Protocol):**
 - **Open-Meteo:** API para consultas climáticas en tiempo real.
 - **Wikipedia (Wikimedia):** Búsqueda de conocimiento externo y resúmenes históricos.
 - **Servicios de Identidad:** Integración con el **VS Agent Admin API** para la gestión de DIDs y canales DIDComm.
 - **OAuth 2.0:** Integración con Google Cloud para autenticación federada de usuarios.
-

5. Explicación de Componentes de IA

La inteligencia de los agentes se basa en tres pilares:

1. **Prompting de Persona:** Definición de la identidad, tono y límites del agente mediante "System Prompts" dinámicos.
 2. **RAG (Retrieval-Augmented Generation):** Capacidad de procesar archivos PDF/TXT subidos por el usuario, indexarlos en Redis y permitir que el agente responda basándose en conocimiento propietario.
 3. **Tool Use (MCP):** El agente puede decidir autónomamente cuándo usar herramientas externas (clima o Wikipedia) para enriquecer sus respuestas con datos reales.
-

6. Resultados Obtenidos

- **Automatización:** Reducción del tiempo de despliegue de un agente verificable de 2 horas (manual) a menos de **5 minutos**.
 - **Identidad Verificable:** El 100% de los agentes creados en la plataforma obtienen automáticamente su estado de "**Verificado**" en la red Verana.
 - **Accesibilidad:** Una interfaz web que permite a usuarios no técnicos participar en el ecosistema de Identidad Descentralizada.
 - **Escalabilidad:** Soporte para múltiples agentes operando simultáneamente bajo una infraestructura compartida optimizada.
-

Documento generado para el entregable final del reto "Agentes IA Verificables con Hologram" — Mayo 2026